Tuần 3: Phân tích bộ dữ liệu DataExpo2009.zip để trả lời câu hỏi sau:

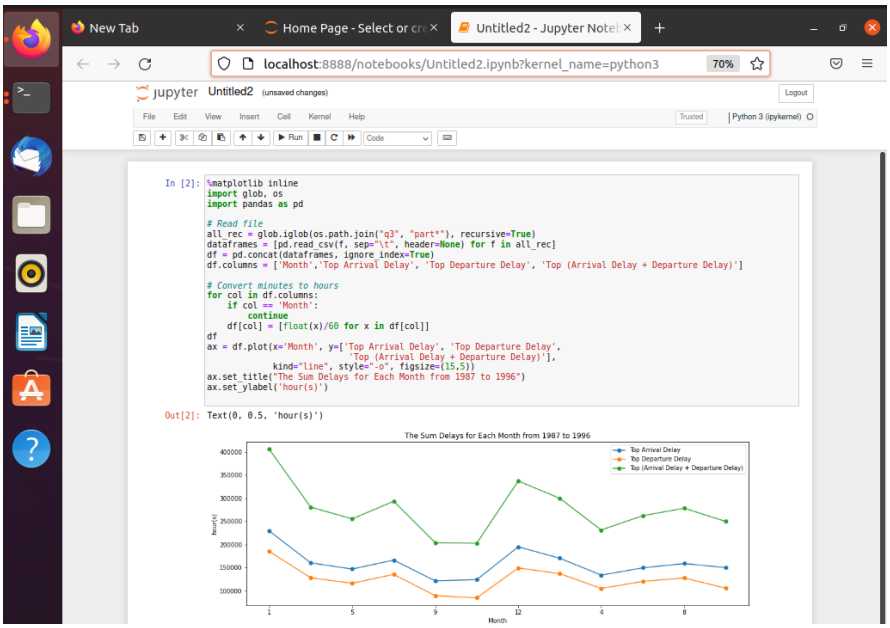
Hãy cho biết tháng nào trong năm có thời gian Departure delay/Arrival delay ít nhất?

A. *Môi trường thực hiện:*

+ Vmware bộ nhớ cấp phát 20G
+ Ubuntu 16
+ Hadoop (HDFS +Yarn) https://mirrors.sonic.net/apache/hadoop/common/hadoop-3.3.1/hadoop-3.3.1.tar.gz
+ Apache Pig https://mirrors.sonic.net/apache/pig/pig-0.17.0/pig-0.17.0.tar.gz

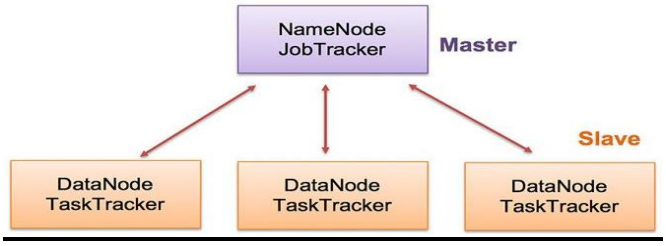
B. ***Thực hiện**: Phân tích bộ dữ liệu từ năm 1987 to 1996 (11GB)*

C. ***Kết quả**: Tháng 10 trong năm có thời gian Departure delay ít nhất / Tháng 9 trong năm có thời gian Arrival delay ít nhất.*

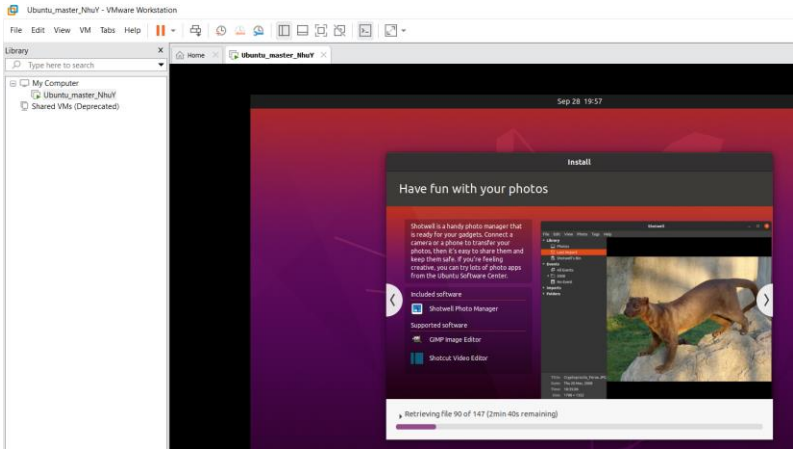


D. *Các bước thực hiện chi tiết*

1. Mô hình triển khai hệ thống Hadoop



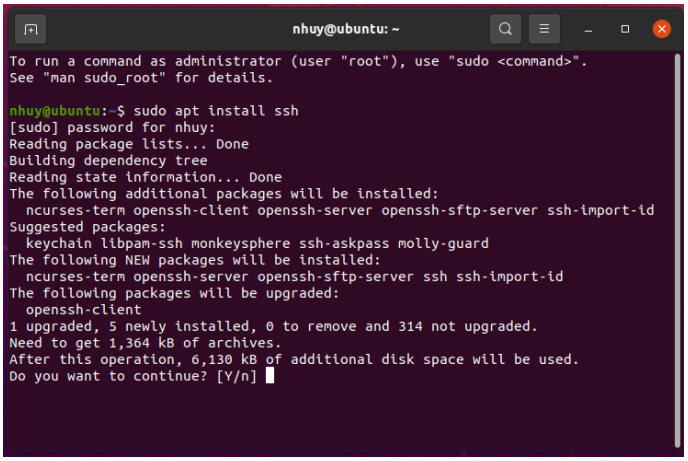
2. Cài đặt Ubuntu trên máy ảo



3. Cài đặt Hadoop

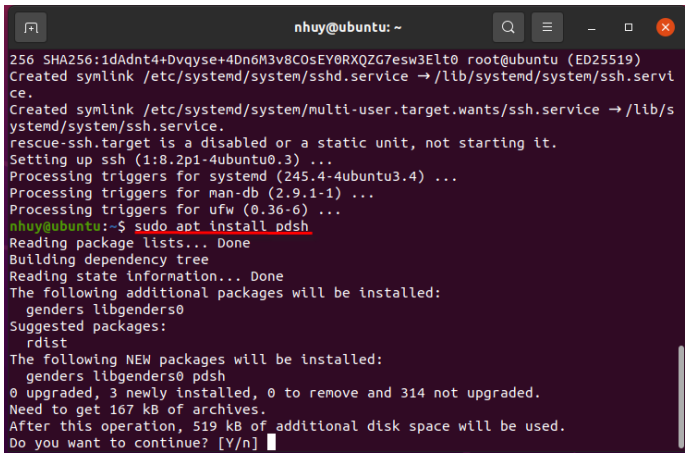
Bước 1: Cài đặt ssh

$ sudo apt install ssh



Bước 2: Cài đặt PDSH

$ sudo apt install pdsh

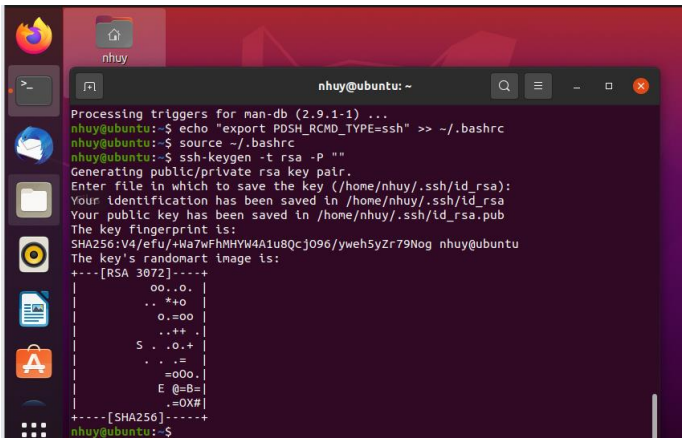


Bước 3: Cấu hình file ~/.bashrc và tạo khóa cho ssh

$ echo "export PDSH_RCMD_TYPE=ssh" >> ~/.bashrc

$ source ~/.bashrc

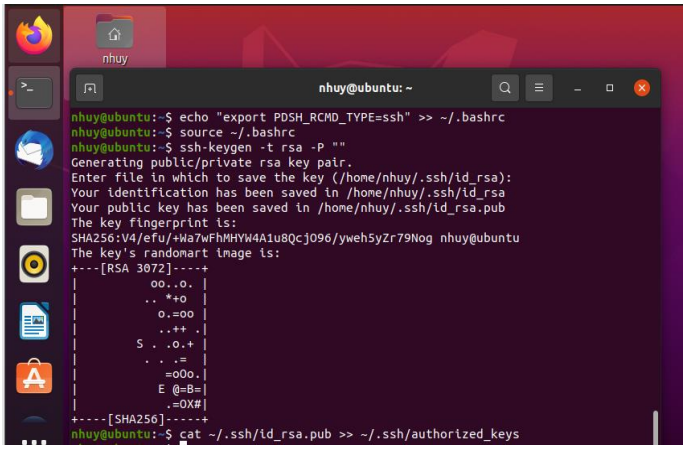
$ ssh-keygen -t rsa -P ""



Bước 4: Cho phép ssh truy cập tới máy cục bộ

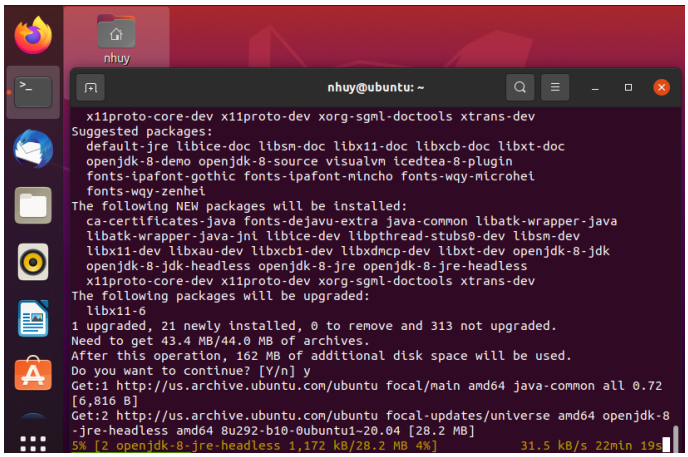
$ cat ~/.ssh/id_rsa.pub >> ~/.ssh/authorized_keys

$ ssh localhost



Bước 5: Cài đặt java version 8

$ sudo apt install openjdk-8-jdk

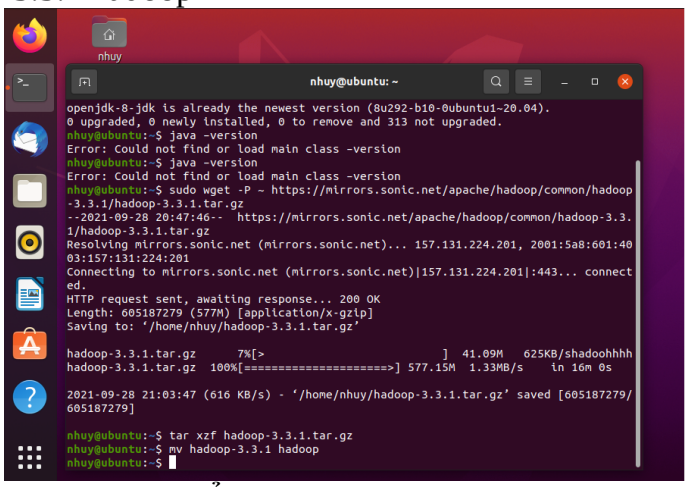


Bước 6: Tải hadoop và cài đặt

$ sudo wget -P ~ https://mirrors.sonic.net/apache/hadoop/common/hadoop-3.3.1/hadoop-3.3.1.tar.gz

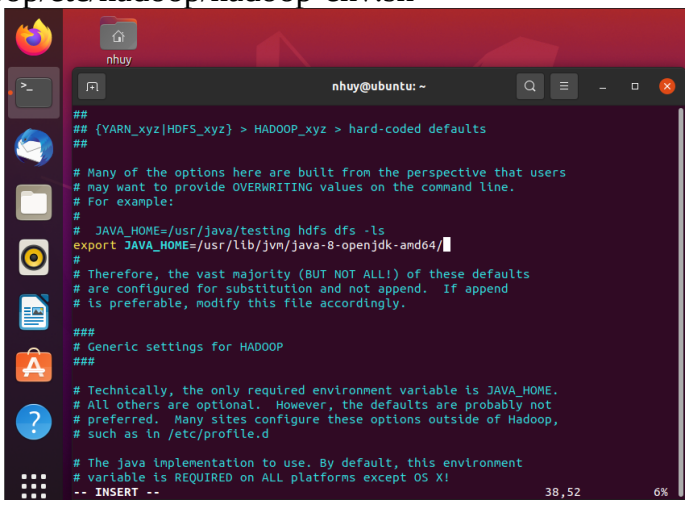
$ tar xzf hadoop-3.3.1.tar.gz

$ mv hadoop-3.3.1 hadoop



Bước 7: Mở file hadoop-env.sh để chỉnh sửa JAVA_HOME

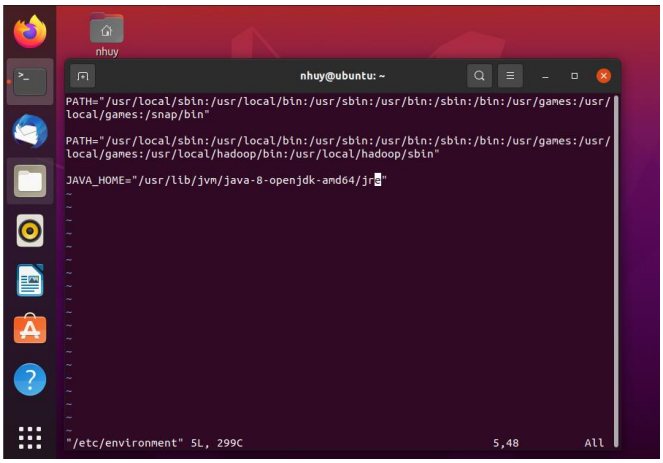
$ vim ~/hadoop/etc/hadoop/hadoop-env.sh



Bước 8: Di chuyển thư mục hadoop qua usr/local/hadoop và mở file environment

$ sudo mv hadoop /usr/local/hadoop

$ sudo vim /etc/environment



Bước 9: Thêm người dùng tên là hadoopuser

$ sudo adduser hadoopuser

$ sudo usermod -aG hadoopuser hadoopuser

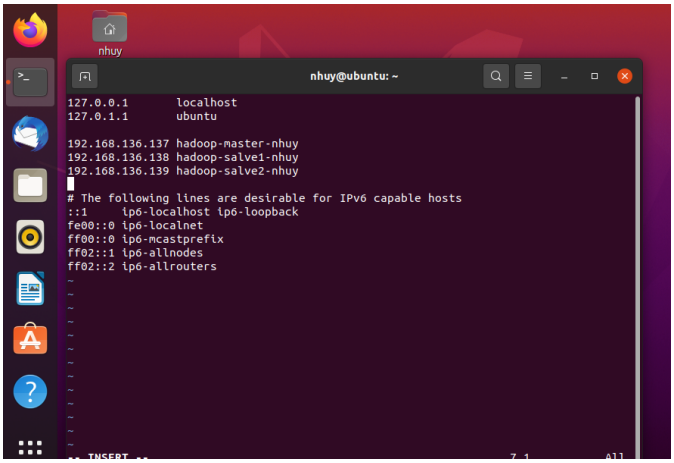
$ sudo chown hadoopuser -R /usr/local/hadoop/

$ sudo chmod g+rwx -R /usr/local/hadoop/

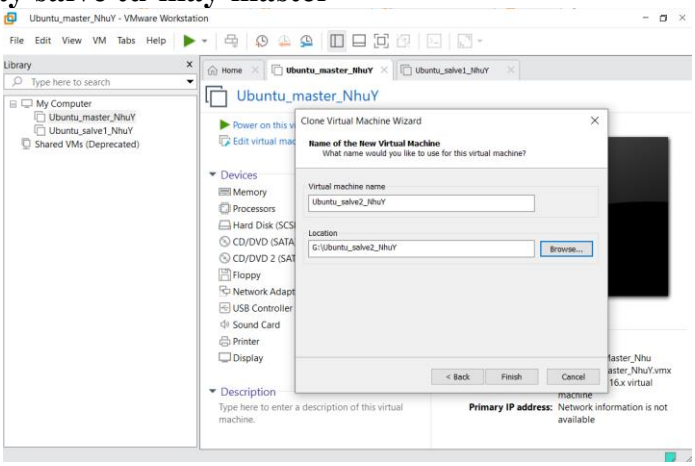
$ sudo adduser hadoopuser sudo

Bước 10: cấu hình file hosts

$ sudo vim /etc/hosts

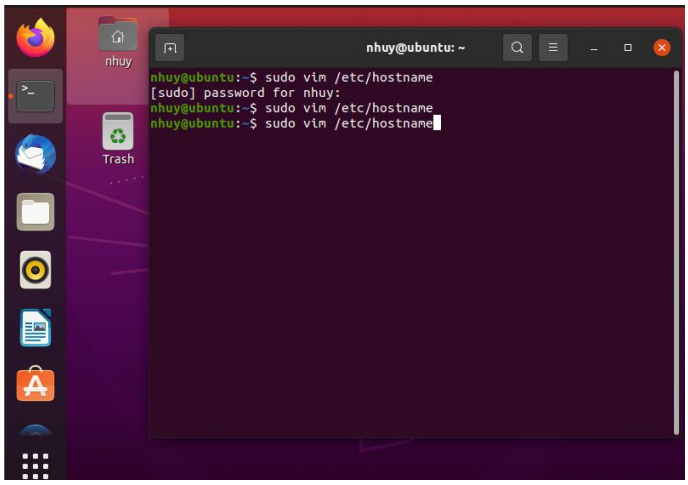


Bước 11: Tạo 2 máy salve từ máy master



Bước 12: Cấu hình file hostname

$ sudo vim /etc/hostname



thêm vào

máy master : hadoop-master

máy salve1 : hadoop-salve1

máy salve2 : hadoop-salve2

Bước 13: Cấu hình trên hadoop-master và hadoopuser

$ su – hadoopuser

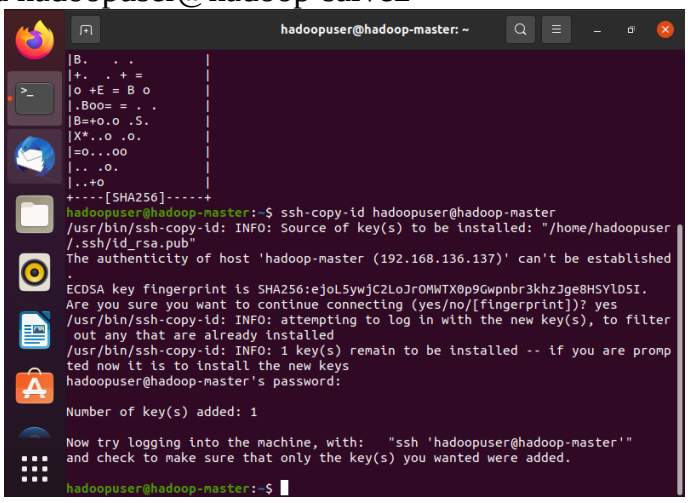
Bước 14: Tạo khóa ssh và sao chép khóa SSH cho các user

$ ssh-keygen -t rsa

$ ssh-copy-id hadoopuser@hadoop-master

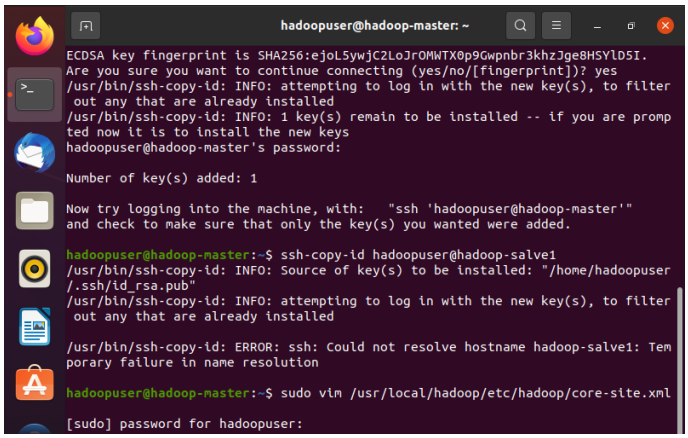
$ ssh-copy-id hadoopuser@hadoop-salve1

$ ssh-copy-id hadoopuser@hadoop-salve2



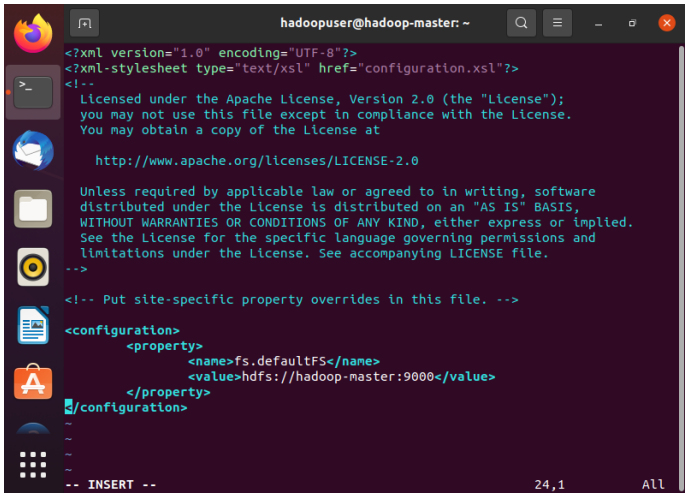
Bước 15: Cấu hình file trên hadoop-master

$ sudo vim /usr/local/hadoop/etc/hadoop/core-site.xml



thêm cấu hình

```
<configuration>
        <property>
                <name>fs.defaultFS</name>
                <value>hdfs://hadoop-master:9000</value>
        </property>
</configuration>
```



$ sudo vim /usr/local/hadoop/etc/hadoop/hdfs-site.xml

thêm cấu hình

```
<configuration>
        <property>
                <name>dfs.namenode.name.dir</name>
                <value>/usr/local/hadoop/data/nameNode</value>
        </property>
        <property>
                <name>dfs.datanode.data.dir</name>
                <value>/usr/local/hadoop/data/dataNode</value>
        </property>
```

```
        <property>
            <name>dfs.replication</name>
            <value>2</value>
        </property>
    </configuration>
```

$ sudo vim /usr/local/hadoop/etc/hadoop/workers

thêm

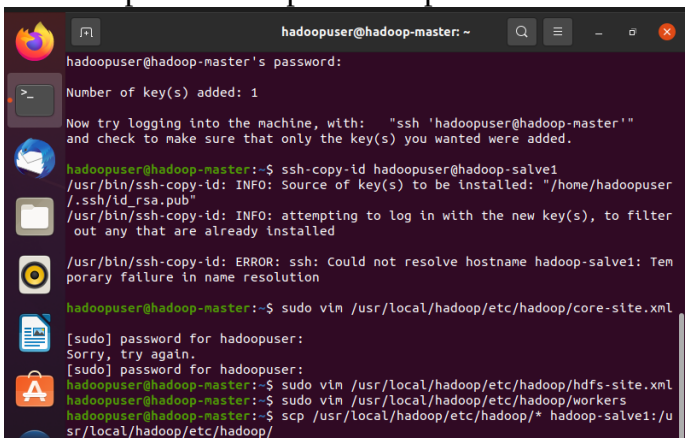
hadoop-salve1

hadoop-salve2

Bước 16: Sao chép cấu hình máy master cho các máy salve

$ scp /usr/local/hadoop/etc/hadoop/* hadoop-salve1:/usr/local/hadoop/etc/hadoop/

$ scp /usr/local/hadoop/etc/hadoop/* hadoop-salve2:/usr/local/hadoop/etc/hadoop/



4. Cài đặt HDFS

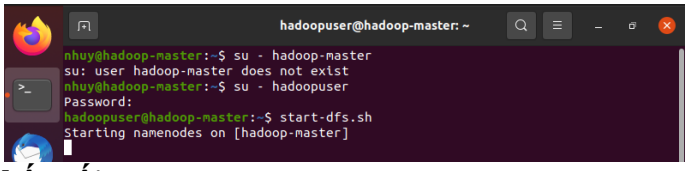
Bước 17: Định dạng lại file HDFS

$ source /etc/environment

$ hdfs namenode –format

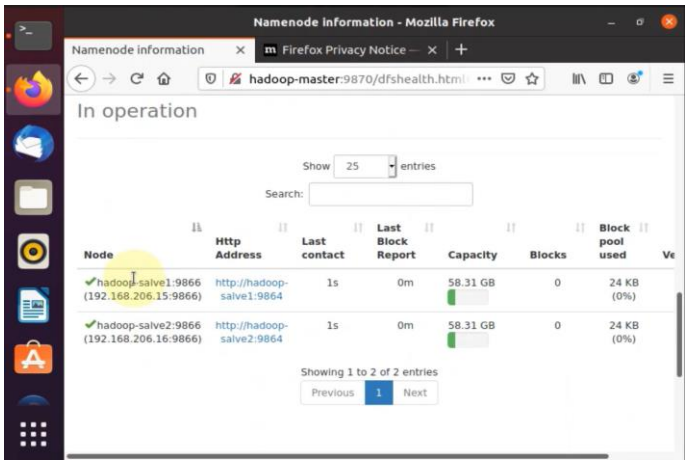
Bước 18: chạy file HDFS

$ start-dfs.sh



Bước 19: kiểm tra kết nối

Truy cập địa chỉ hadoop-master:9870



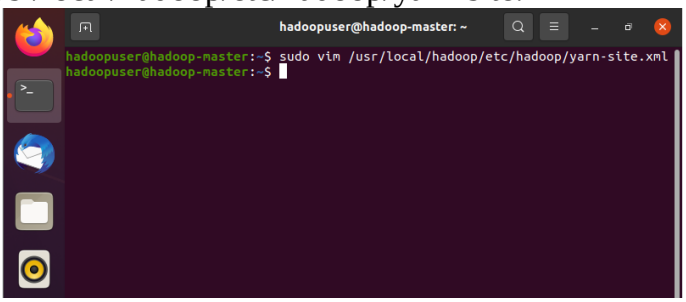
5. Cài đặt Yarn

Bước 20: Cấu hình file YARN

```
$ export HADOOP_HOME="/usr/local/hadoop"
$ export HADOOP_COMMON_HOME=$HADOOP_HOME
$ export HADOOP_CONF_DIR=$HADOOP_HOME/etc/hadoop
$ export HADOOP_HDFS_HOME=$HADOOP_HOME
$ export HADOOP_MAPRED_HOME=$HADOOP_HOME
$ export HADOOP_YARN_HOME=$HADOOP_HOME
```

Bước 21: Mở file yarn-site.xml

```
$ sudo vim /usr/local/hadoop/etc/hadoop/yarn-site.xml
```



thêm

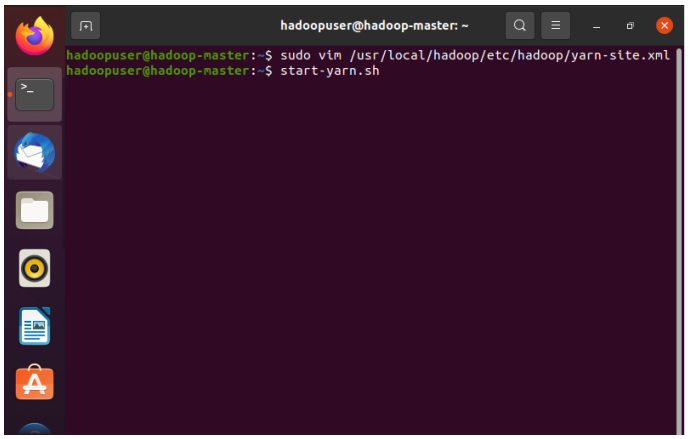
```
<property>
        <name>yarn.resourcemanager.hostname</name>
        <value>hadoop-master</value>
</property>
```

Máy salve1 và máy salve2
thêm

```
<property>
        <name>yarn.resourcemanager.hostname</name>
        <value>hadoop-master</value>
</property>
```

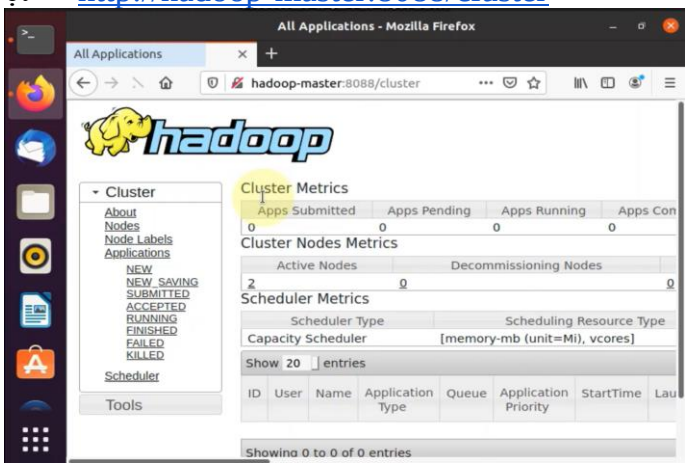
Bước 22: Chạy file yarn

$ start-yarn.sh



Bước 23: Kiểm tra

Mở trình duyệt -> http://hadoop-master:8088/cluster

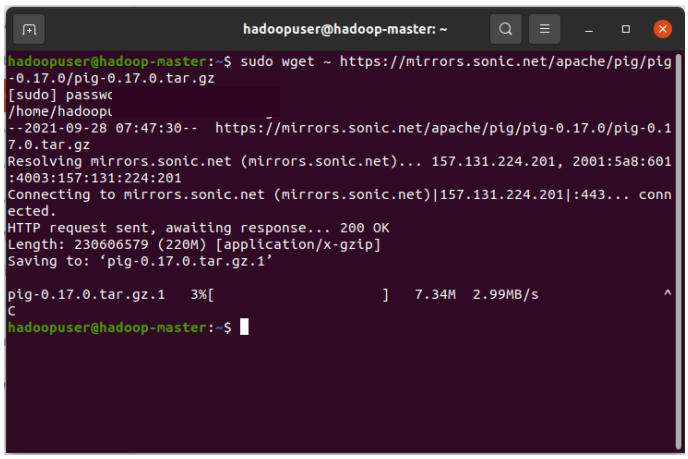


6. Cài đặt Apache Pig

Bước 24: Tải file apache pig

$ sudo wget ~ https://mirrors.sonic.net/apache/pig/pig-0.17.0/pig-0.17.0.tar.gz

$ tar -xvf pig-0.17.0.tar.gz



Bước 25: Cấu hình file .bashrc

$ sudo nano ~/.bashrc

Kéo xuống dưới cùng của file để export các đường dẫn cần thiết và đường dẫn apache pig.

export JAVA_HOME=/usr/lib/jvm/java-8-openjdk-amd64

export PATH=$PATH:$JAVA_HOME/bin

export HADOOP_HOME=/usr/local/hadoop

export HADOOP_COMMON_HOME=$HADOOP_HOME

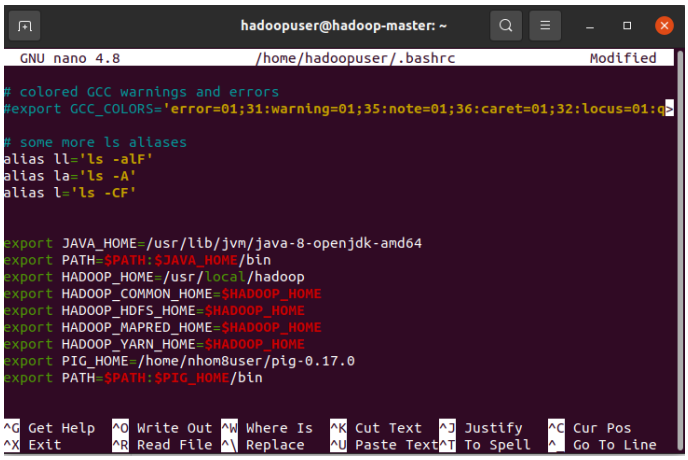
export HADOOP_HDFS_HOME=$HADOOP_HOME

export HADOOP_MAPRED_HOME=$HADOOP_HOME

export HADOOP_YARN_HOME=$HADOOP_HOME

export PIG_HOME=/home/hadoopuser/pig-0.17.0

export PATH=$PATH:$PIG_HOME/bin



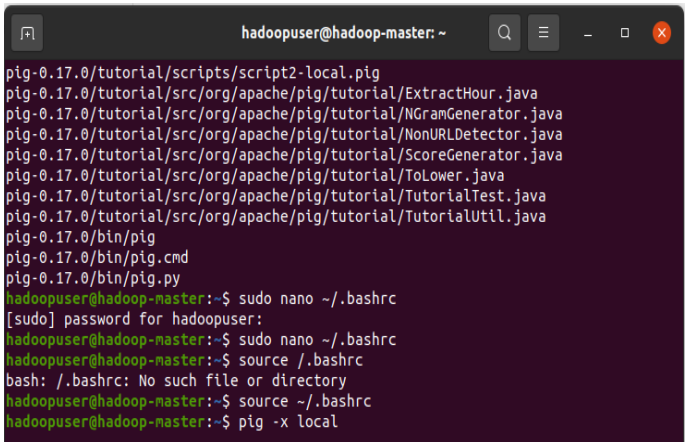
Bước 26: Lưu lại file cấu hình xong

$ source /.bashrc

Có 2 chế độ chạy pig một là chạy local chạy trên máy mình, hai là chạy trên HDFS của hadoop:

Bước 27: Chạy chế độ local

$ pig -x local



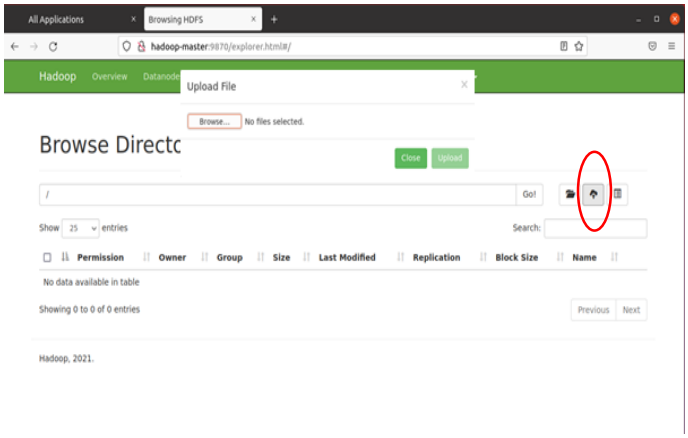
Bước 28: Chạy chế độ HDFS của Hadoop

Chú ý khi chạy file trên HDFS ta phải khởi động cụm máy hadoop và phải chạy ít nhất là 1 worker để nhận dữ liệu.

$ start-dfs.sh

$ start-yarn.sh

Lên trang hadoop-master:9870 vào mục Utillities nhấn vào Browse the file system để kiểm tra thư mục và các file và đẩy dữ liệu lên HDFS.



7. Cài đặt bài toán

Yêu cầu: Phân tích bộ dữ liệu DataExpo2009.zip để trả lời câu hỏi sau:

Hãy cho biết tháng nào trong năm có thời gian Departure delay/Arrival delay ít nhất.

Bước 1: Load dữ liệu từ năm 1987 đến 1996 lên hệ thống bằng ngôn ngữ Pig.

```
dataset_raw = LOAD
'/home/hadoopuser/Desktop/{1987,1988,1989,1990,1991,1992,1993,1994,1995,1
996}.csv'
```

USING PigStorage(',') AS (Year:chararray, Month:chararray, DayofMonth:chararray,

DayOfWeek:chararray, DepTime:chararray, CRSDepTime:chararray, ArrTime:chararray,

CRSArrTime:chararray, UniqueCarrier:chararray, FlightNum:chararray,

TailNum:chararray, ActualElapsedTime:chararray, CRSElapsedTime:chararray,

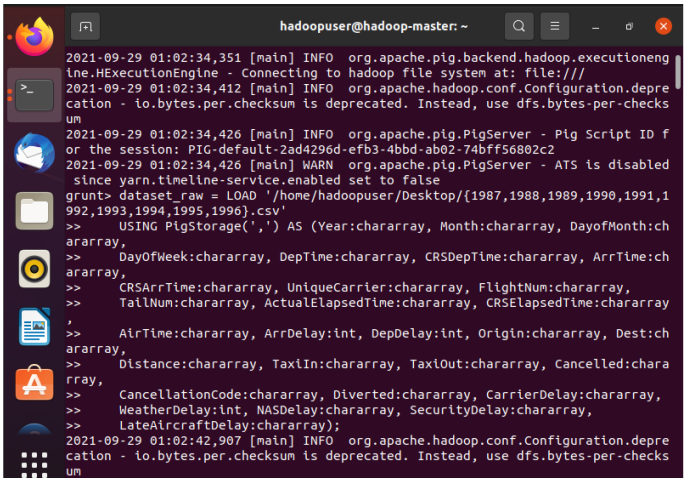
AirTime:chararray, ArrDelay:int, DepDelay:int, Origin:chararray, Dest:chararray,

Distance:chararray, TaxiIn:chararray, TaxiOut:chararray, Cancelled:chararray,

CancellationCode:chararray, Diverted:chararray, CarrierDelay:chararray,

WeatherDelay:int, NASDelay:chararray, SecurityDelay:chararray,

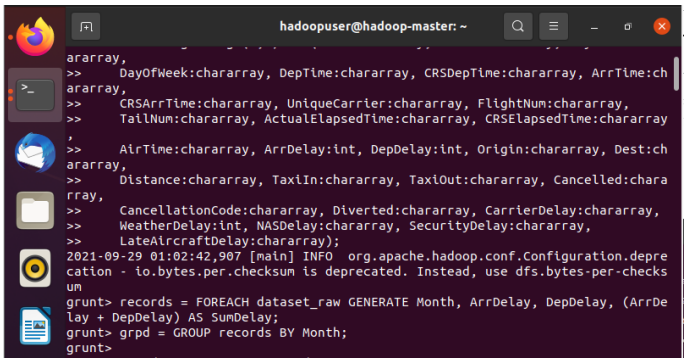
LateAircraftDelay:chararray);



Bước 2: Lọc dữ liệu lấy 4 cột cần của dữ liệu và group by theo tháng

records = FOREACH dataset_raw GENERATE Month, ArrDelay, DepDelay, (ArrDelay + DepDelay) AS SumDelay;

grpd = GROUP records BY Month;



Bước 3: Tính tổng thời gian của tất cả chuyến bay khởi hành trễ của từng tháng trong các năm từ 1987 đến 1996

top_delays = FOREACH grpd {

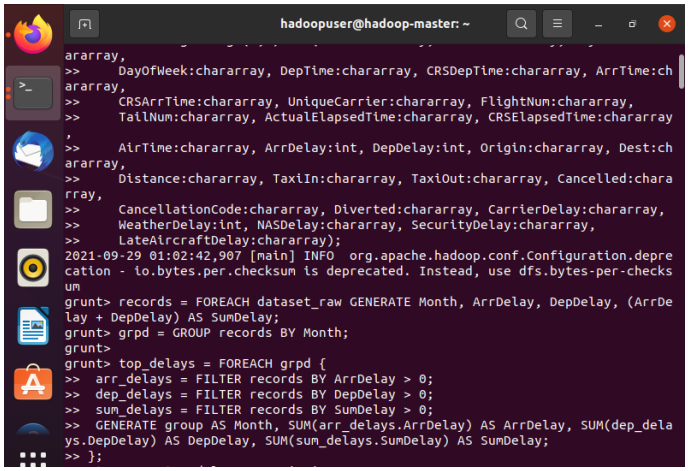
arr_delays = FILTER records BY ArrDelay > 0;

dep_delays = FILTER records BY DepDelay > 0;

sum_delays = FILTER records BY SumDelay > 0;

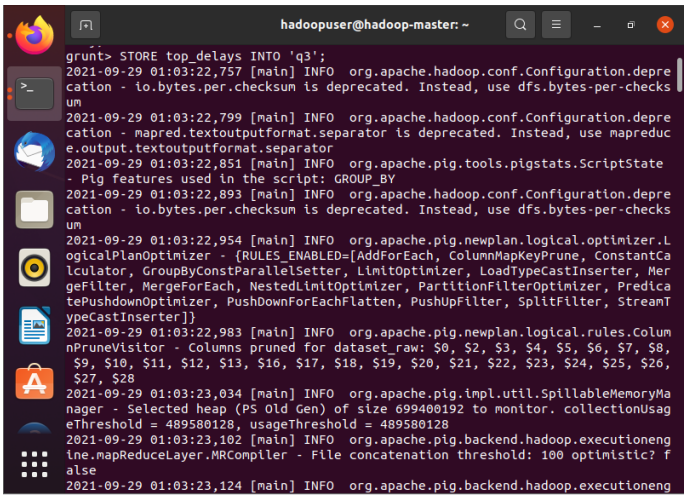
GENERATE group AS Month, SUM(arr_delays.ArrDelay) AS ArrDelay, SUM(dep_delays.DepDelay) AS DepDelay, SUM(sum_delays.SumDelay) AS SumDelay;

};



Bước 4: Lưu dữ liệu lọc được từ bước 3 vào thư mục q3

STORE top_delays INTO 'q3';



Bước 5: Vẽ biểu đồ tổng thời gian các chuyến bay trễ của từng tháng trong năm 1987, 1988, 1989, 1990, 1991, 1992, 1993, 1994, 1995, 1996 bằng ngôn ngữ python.

```
%matplotlib inline

import glob, os

import pandas as pd

# Read file

all_rec = glob.iglob(os.path.join("q3", "part*"), recursive=True)

dataframes = [pd.read_csv(f, sep="\t", header=None) for f in all_rec]

df = pd.concat(dataframes, ignore_index=True)

df.columns = ['Month','Top Arrival Delay', 'Top Departure Delay', 'Top (Arrival Delay + Departure Delay)']

# Convert minutes to hours

for col in df.columns:

    if col == 'Month':

        continue

    df[col] = [float(x)/60 for x in df[col]]

df

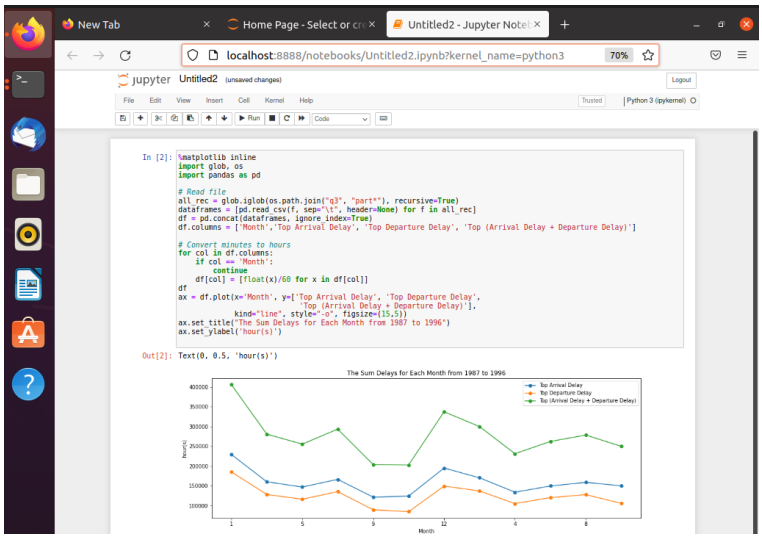
ax = df.plot(x='Month', y=['Top Arrival Delay', 'Top Departure Delay',

                           'Top (Arrival Delay + Departure Delay)'],

             kind="line", style="-o", figsize=(15,5))
```

ax.set_title("The Sum Delays for Each Month from 1987 to 1996")

ax.set_ylabel('hour(s)')



E. Tài liệu tham khảo

[1] https://community.amstat.org/jointscsg-section/dataexpo/dataexpo2009

[2] https://viblo.asia/p/hadoop-cai-dat-hadoop-tren-ubuntu-phan-1-4dbZNo3qlYM

[3] https://pig.apache.org/docs/r0.17.0/start.html

[4] https://chih-ling-hsu.github.io/2018/06/14/flight#q2-how-many-flights-were-delayed-caused-by-weather-between-2000--2005-please-show-the-counting-for-each-year