TÀI LIỆU KỸ THUẬT

RAG Từ Cơ Bản Đến Thực Chiến

Xây Hệ Thống AI Biết Tra Cứu Dữ Liệu

Lộ trình thực chiến dành cho kỹ sư phần mềm: từ lúc có dữ liệu lộn xộn cho đến khi triển khai hệ thống AI tra cứu chính xác, tối ưu chi phí và độ trễ ở quy mô lớn.

Mục lục

Mở đầu

Phần 1: RAG là gì và vì sao cần RAG

Chương 1: LLM giới hạn ở đâu và vì sao cần RAG

1.1 Ảo giác và giới hạn ngữ cảnh dưới góc nhìn Developer

1.2 So sánh RAG và Fine-tuning cho ứng dụng phần mềm

Chương 2: RAG hoạt động như thế nào (high-level pipeline)

2.1 Luồng đi của dữ liệu: Từ API Request đến Response

2.2 Kiến trúc Naive RAG vs Advanced RAG cho Web App

Chương 3: Các thành phần chính: embedding, vector DB, retriever, generator

3.1 Retriever và Generator: Interface và sự tương tác

3.2 Vai trò của Embedding và Vector Database trong Stack công nghệ

Phần 2: Xây nền tảng dữ liệu cho RAG

Chương 4: Embedding là gì và cách chọn Model phù hợp

4.1 Cơ chế hoạt động của Embedding dưới góc nhìn lập trình

4.2 Tiêu chí chọn Embedding API vs Self-hosted

Chương 5: Chunking: Chiến lược phân mảnh tài liệu

5.1 Các thuật toán Chunking phổ biến cho Developer

5.2 Tối ưu Chunk Size và Overlap cho ứng dụng thực tế

Chương 6: Vector Database: Lựa chọn và tích hợp

6.1 Kiến trúc và cách hoạt động của Vector DB

6.2 So sánh FAISS, Pinecone và Weaviate cho Software Project

Chương 7: Xây dựng Pipeline Indexing tự động

7.1 Thiết kế luồng ETL cho dữ liệu Vector

7.2 Quản lý Metadata và Filtering trong ứng dụng

Phần 3: Tối ưu hóa Retrieval và chất lượng phản hồi

Chương 8: Similarity Search và các phép đo khoảng cách

8.1 Cosine Similarity và Euclidean Distance trong thực tế

8.2 Thuật toán ANN: Tăng tốc độ tìm kiếm cho ứng dụng lớn

Chương 9: Hybrid Search: Kết hợp Keyword và Vector

9.1 Tại sao Vector Search thuần túy là chưa đủ?

9.2 Triển khai Hybrid Search với BM25 và Vector

Chương 10: Reranking: Kỹ thuật lọc kết quả chính xác

10.1 Cơ chế Cross-Encoders trong Pipeline RAG
10.2 Cân bằng giữa Accuracy và API Latency
Chương 11: Context Management và Prompt Engineering
11.1 Chiến thuật sắp xếp ngữ cảnh trong Prompt
11.2 Xây dựng Guardrails cho câu trả lời của AI

Phần 4: Kiến trúc RAG nâng cao cho ứng dụng phức tạp

Chương 12: Multi-hop RAG: Truy xuất đa luồng
12.1 Kỹ thuật Query Decomposition trong Code
12.2 Tổng hợp kết quả từ nhiều bước truy xuất
Chương 13: Agentic RAG: AI tự động hóa quy trình
13.1 Vòng lặp ReAct (Reason + Act) cho RAG
13.2 Xây dựng Tool-set cho RAG Agent
Chương 14: Quản lý Memory và Long-term Context
14.1 Thiết kế Session và Chat History Store
14.2 Kỹ thuật tóm tắt ngữ cảnh để tiết kiệm Token
Chương 15: Kết hợp RAG với SQL và Graph Database
15.1 Text-to-SQL: Truy vấn DB an toàn
15.2 GraphRAG: Tận dụng mối quan hệ giữa các thực thể

Phần 5: Triển khai thực tế và vận hành ứng dụng

Chương 16: Xây dựng Chatbot tài liệu nội bộ
16.1 Kiến trúc Full-stack cho Chatbot RAG
16.2 Xử lý đa định dạng file: PDF, Markdown, Wiki
Chương 17: Nâng cấp Search Engine với RAG
17.1 Tích hợp RAG vào luồng tìm kiếm hiện có
17.2 Trích dẫn nguồn và tính minh bạch của dữ liệu
Chương 18: Phát triển API RAG với FastAPI và Next.js
18.1 Xây dựng Backend API hỗ trợ Streaming
18.2 Frontend Integration và xử lý Stream dữ liệu
Chương 19: Scaling, Latency và Tối ưu hóa chi phí
19.1 Kỹ thuật Caching cho ứng dụng RAG
19.2 Monitoring và Quản lý chi phí Token
Chương 20: Những lỗi phổ biến và Checklist Production
20.1 Top 5 sai lầm kiến trúc khiến dự án RAG thất bại
20.2 Checklist sẵn sàng cho Production

Mở đầu

Bạn đang đọc những dòng này hẳn đã từng ít nhất một lần tự hỏi: làm sao để tích hợp LLM vào ứng dụng thực tế mà không bị ảo giác, không quá đắt đỏ, và không biến sản phẩm thành một hộp đen khó bảo trì? Nếu bạn là một kỹ sư phần mềm — backend, frontend, fullstack, data engineer — đã có kinh nghiệm với API, database, và kiến trúc microservices, nhưng chưa từng đào sâu vào machine learning, thì cuốn sách này được viết dành cho bạn.

Vì sao cuốn sách này ra đời?

Tôi thấy quá nhiều đội ngũ kỹ thuật lao vào xây dựng tính năng "AI" bằng cách gọi API GPT, nhồi nhét dữ liệu vào prompt, và hy vọng nó hoạt động. Kết quả thường là một prototype ấn tượng nhưng sụp đổ ngay khi có người dùng thật: trả lời sai, timeout, chi phí token tăng vọt, và không ai dám bảo trì. RAG — Retrieval-Augmented Generation — nghe có vẻ là giải pháp thần kỳ, nhưng thực tế là một bài toán kỹ thuật phần mềm nghiêm túc. Nó đòi hỏi bạn phải hiểu dữ liệu của mình, thiết kế pipeline xử lý chắc chắn, và đưa ra hàng loạt quyết định đánh đổi (trade-off) giữa độ chính xác, tốc độ, và chi phí.

Cuốn sách này không phải là một tuyển tập lý thuyết AI hay một hướng dẫn sử dụng thư viện LangChain. Nó là một lộ trình thực chiến dành cho kỹ sư phần mềm: từ lúc bạn có một đống tài liệu nội bộ lộn xộn cho đến khi bạn deploy một API RAG có thể phục vụ hàng nghìn yêu cầu mỗi giây.

Cuốn sách này dành cho ai?

Cụ thể hơn, bạn là người phù hợp nếu:

- Bạn đã từng xây dựng một REST API, hiểu biết về cơ sở dữ liệu (SQL/NoSQL), và quen với khái niệm microservices.
- Bạn muốn tích hợp khả năng tra cứu thông minh vào sản phẩm web/app hoặc hệ thống nội bộ, nhưng chưa biết bắt đầu từ đâu.
- Bạn đã thử gọi API ChatGPT để trả lời câu hỏi từ dữ liệu riêng, nhưng kết quả không đáng tin cậy, và bạn muốn một giải pháp có kiểm soát.
- Bạn không muốn trở thành chuyên gia deep learning; bạn chỉ muốn một hệ thống hoạt động, có thể đo lường và bảo trì.

Nếu bạn thuộc tuýp kỹ sư thích hiểu bản chất trước khi code, và không ngại đọc về kiến trúc hệ thống, thì bạn đã đến đúng nơi.

Bạn sẽ đạt được điều gì sau khi đọc cuốn sách này?

Tôi không hứa bạn sẽ trở thành chuyên gia AI chỉ sau một cuốn sách. Nhưng tôi cam kết bạn sẽ:

- Hiểu rõ cơ chế hoạt động của từng thành phần trong pipeline RAG: embedding, chunking, vector database, retrieval, reranking, prompt design.
- Có khả năng lựa chọn công cụ và thiết kế kiến trúc dựa trên yêu cầu cụ thể về độ trễ, độ chính xác, và ngân sách.
- Xây dựng được một pipeline RAG hoàn chỉnh từ dữ liệu thô đến API production, bằng code mẫu thực tế (Python, FastAPI, Next.js).
- Tránh được những lỗi phổ biến khiến nhiều đội ngũ mất hàng tháng trời để debug.
- Tự tin đánh giá và tối ưu hệ thống RAG của mình khi nó vận hành ở quy mô thực.

Nói ngắn gọn: bạn sẽ có một framework tư duy để biến RAG từ một khái niệm trend thành một phần trong bộ công cụ kỹ thuật hàng ngày của mình.

Cách đọc cuốn sách này

Cuốn sách được tổ chức theo vòng đời phát triển của một hệ thống RAG, gồm 5 phần với 13 chương. Bạn có thể đọc tuần tự từ đầu đến cuối — đó là cách tôi khuyến khích nếu bạn muốn xây nền tảng vững chắc. Nhưng nếu bạn đã có kinh nghiệm và cần tra cứu nhanh, mỗi chương được thiết kế tương đối độc lập, với các phần tóm tắt và checklist ở cuối.

Để tận dụng tối đa cuốn sách:

- Đừng bỏ qua phần cơ chế (thường nằm ở đầu mỗi chương). Hiểu tại sao chunking ảnh hưởng đến chất lượng retrieval còn quan trọng hơn biết cú pháp của thư viện nào.
- Chạy code mẫu. Các ví dụ được chọn lọc để minh họa pattern, không phải boilerplate. Bạn sẽ cần điều chỉnh chút ít cho phù hợp với dữ liệu thật.
- Ghi chú trade-off. Mỗi quyết định kỹ thuật đều có cái giá của nó. Tôi sẽ chỉ ra rõ ràng: cái này nhanh hơn nhưng đắt hơn, cái kia chính xác hơn nhưng chậm hơn.

Những điều cuốn sách này không bao gồm

Để giữ trọng tâm và độ dài hợp lý, tôi cố tình bỏ qua:

- Toán học sâu về transformer hay attention. Bạn không cần nó để xây RAG.
- Huấn luyện model từ đầu hay fine-tuning chi tiết. Chúng tôi chỉ so sánh với RAG để bạn hiểu khi nào nên dùng cách nào.
- Lịch sử AI hay triết lý AGI. Cuốn sách này thực dụng, không mơ mộng.
- Code hoàn chỉnh cho mọi thư viện. Thay vào đó, bạn sẽ thấy pattern và logic cốt lõi — bạn có thể áp dụng với bất kỳ framework nào.

Lộ trình bắt đầu

Trang tiếp theo sẽ đưa bạn vào Part 1, nơi chúng ta cùng nhìn lại giới hạn của LLM thuần túy — không phải để chê bai, mà để hiểu tại sao RAG là một bước tiến cần thiết trong kiến trúc phần mềm. Nếu bạn đã sẵn sàng để xây dựng một hệ thống AI thực sự hữu ích, hãy lật trang và bắt đầu.

Tôi hy vọng cuốn sách này sẽ trở thành người bạn đồng hành đáng tin cậy trên hành trình kỹ thuật của bạn.

Chương 1: LLM giới hạn ở đâu và vì sao cần RAG

1.1 Ảo giác và giới hạn ngữ cảnh dưới góc nhìn Developer

Ảo giác và giới hạn ngữ cảnh của LLM

Bạn đang xây dựng một chatbot nội bộ cho công ty. Nhân viên hỏi: "Chính sách nghỉ thai sản hiện tại là bao nhiêu tuần?". Chatbot trả lời ngay lập tức: "Theo bộ luật lao động, thời gian nghỉ thai sản là 6 tháng." Câu trả lời nghe có vẻ hợp lý, nhưng hoàn toàn sai — chính sách nội bộ của công ty bạn là 12 tuần, và con số "6 tháng" là thông tin từ một bối cảnh khác, không liên quan. Chatbot không cố ý nói dối. Nó chỉ đang làm đúng những gì nó được huấn luyện: dự đoán token tiếp theo một cách có xác suất cao nhất dựa trên hàng tỷ mẫu văn bản từ Internet. Vấn đề là nó không biết nó không biết.

Cơ chế "next token prediction" — nguồn gốc của ảo giác

LLM (Large Language Model) hoạt động dựa trên một nguyên lý duy nhất: dự đoán token tiếp theo trong chuỗi. Khi bạn gõ một câu hỏi, model không "hiểu" nghĩa của câu hỏi theo cách con người hiểu. Nó chỉ tính toán xác suất cho hàng nghìn token có thể xuất hiện tiếp theo, dựa trên toàn bộ văn bản nó đã thấy trong quá trình huấn luyện. Token có xác suất cao nhất sẽ được chọn, rồi lặp lại cho đến khi tạo ra câu trả lời hoàn chỉnh.

Điều này giải thích tại sao LLM có xu hướng "bịa" thông tin khi không có ngữ cảnh cụ thể. Nếu model chưa từng thấy chính sách nội bộ của công ty bạn trong dữ liệu huấn luyện, nó sẽ suy luận từ các mẫu chung chung — ví dụ: văn bản pháp luật lao động Việt Nam nói chung — và đưa ra câu trả lời trung bình có xác suất cao nhất. Kết quả là một câu trả lời trôi chảy, tự tin nhưng sai sự thật. Đây chính là **ảo giác (hallucination)** — hiện tượng model sinh ra nội dung không chính xác nhưng có hình thức thuyết phục.

Ví dụ về ảo giác trong môi trường doanh nghiệp

Hãy xem xét một kịch bản điển hình: một chatbot hỗ trợ kỹ thuật cho phần mềm CRM nội bộ. Nhân viên hỏi: "Làm sao để xuất báo cáo doanh thu tháng?". Chatbot trả lời với một hướng dẫn chi tiết gồm 5 bước, kèm tên menu và nút bấm. Nhìn qua, hướng dẫn có vẻ chuyên nghiệp. Nhưng thực tế, phần mềm CRM đó không hề có chức năng xuất báo cáo doanh thu — nó chỉ là một module quản lý khách hàng đơn thuần. Chatbot đã "học" cách xuất báo cáo từ các hệ thống CRM khác (như Salesforce) và áp dụng một cách máy móc.

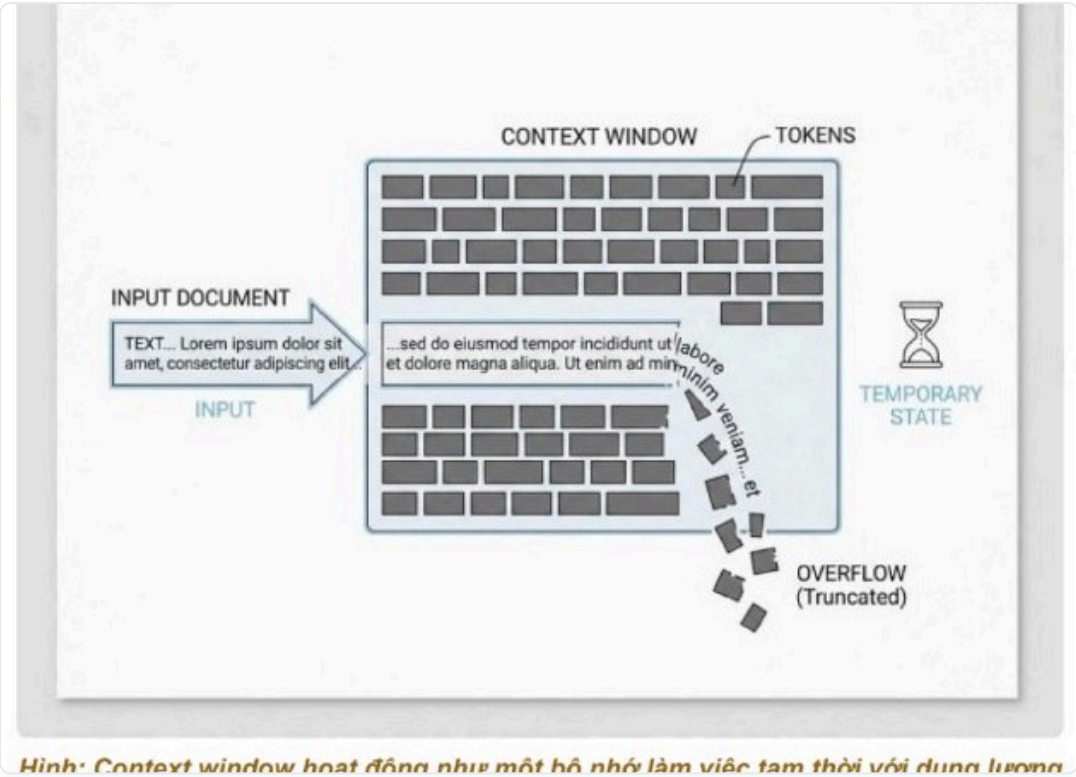
Trường hợp này không phải lỗi dữ liệu hay lỗi lập trình. Đó là hệ quả tất yếu của cơ chế next-token prediction: model không có khả năng kiểm chứng thông tin với "ground truth" bên ngoài. Nó chỉ biết sắp xếp các token sao cho giống với văn bản nó đã thấy nhất, bất kể nội dung đó có thực sự đúng trong bối cảnh hiện tại hay không.

Giới hạn ngữ cảnh (Context Window) — bộ nhớ làm việc có hạn

LLM không chỉ thiếu kiến thức thực tế, nó còn có một giới hạn vật lý: **context window** — kích thước tối đa của văn bản mà model có thể "nhìn thấy" tại một thời điểm. Đây là bộ nhớ làm việc tạm thời của model. Ví dụ, GPT-4 có context window 8,192 token (khoảng 6,000 từ tiếng Anh), trong khi các phiên bản mới hơn như Claude 3 có thể lên tới 200,000 token. Dù con số có lớn đến đâu, nó vẫn là hữu hạn.

Khi bạn gửi một câu hỏi kèm theo tài liệu tham khảo dài, model chỉ có thể "nhìn" vào phần nằm trong context window. Nếu tài liệu quá dài, phần đầu hoặc cuối sẽ bị cắt bỏ, tùy vào cơ chế của từng model. Điều này dẫn đến mất thông tin quan trọng. Hơn nữa, model không có trí nhớ dài hạn — khi kết thúc phiên hội thoại, tất cả ngữ cảnh biến mất. Lần hỏi sau, nó bắt đầu lại từ đầu.

> ***Một ẩn dụ hữu ích:*** *Hãy tưởng tượng bạn đang trả lời email hỗ trợ khách hàng, nhưng bạn chỉ được phép nhìn vào một tờ giấy ghi chú nhỏ (context window). Mọi thông tin nằm ngoài tờ giấy đó là vô hình với bạn. Bạn không thể tra cứu cơ sở dữ liệu, không thể hỏi đồng nghiệp, và cũng không thể nhớ gì từ cuộc hội thoại trước. LLM cũng ở trong hoàn cảnh đó, chỉ khác là nó trả lời rất nhanh và rất tự tin.*



Hình: Context window hoạt động như một bộ nhớ làm việc tạm thời với dung lượng hữu hạn. Dữ liệu vượt quá giới hạn bị cắt bỏ.

Kiến thức tĩnh — dữ liệu huấn luyện lỗi thời

Một giới hạn quan trọng khác là **kiến thức tĩnh (static knowledge)**. LLM được huấn luyện trên một tập dữ liệu khổng lồ được thu thập tại một thời điểm nhất định. Sau khi huấn luyện, kiến thức của model bị "đóng băng". Nếu bạn hỏi về một sự kiện mới xảy ra hôm qua, model không thể biết — trừ khi nó được fine-tune lại hoặc truy cập vào nguồn dữ liệu bên ngoài.

Trong bối cảnh doanh nghiệp, kiến thức tĩnh là một vấn đề nghiêm trọng. Chính sách nhân sự thay đổi hàng quý, bảng giá sản phẩm cập nhật hàng tháng, tài liệu kỹ thuật được bổ sung hàng tuần. Một model được huấn luyện từ tháng 1 sẽ hoàn toàn mù tịt về những thay đổi diễn ra sau đó. Không thể retrain model hàng tuần vì chi phí quá lớn — việc huấn luyện GPT-4 ước tính tốn hàng chục triệu đô la và hàng tháng trời.

Liên kết đến vấn đề lớn hơn

Ảo giác, context window hữu hạn và kiến thức tĩnh không phải là những lỗi nhỏ có thể bỏ qua. Chúng là những rào cản căn bản khiến LLM thuần túy không thể được tin cậy trong các ứng dụng doanh nghiệp — nơi thông tin phải chính xác, cập nhật và có thể truy xuất được đến nguồn gốc. Bạn không thể giao một chiếc chatbot không biết nó đang nói gì cho khách hàng hoặc nhân viên của mình.

Khi đã hiểu rõ những giới hạn này, câu hỏi tiếp theo là: liệu RAG có phải là câu trả lời duy nhất? Chúng ta sẽ đặt RAG lên bàn cân so sánh với Fine-tuning trong phần tiếp theo để xác định chiến lược tối ưu cho doanh nghiệp.

1.2 So sánh RAG và Fine-tuning cho ứng dụng phần mềm

So sánh RAG và Fine-tuning: Khi nào dùng gì?

Việc chọn sai giải pháp giữa Fine-tuning và RAG không chỉ lãng phí nguồn lực mà còn tạo ra các vấn đề kỹ thuật khó gỡ. Để đưa ra quyết định đúng đắn, chúng ta cần phân tích bản chất của hai phương pháp này thông qua lăng kính Behavioral Tuning và Knowledge Injection.

Bản chất của Fine-tuning và RAG

Fine-tuning là quá trình huấn luyện bổ sung trên một mô hình đã được pre-train, sử dụng dữ liệu có nhãn trong một lĩnh vực cụ thể. Mục tiêu là điều chỉnh trọng số của mô hình để nó "học" thêm kiến thức hoặc thay đổi hành vi. Ví dụ: fine-tune GPT-3.5 trên hàng nghìn hội thoại hỗ trợ kỹ thuật để chatbot trở nên chuyên nghiệp và chính xác hơn trong lĩnh vực đó. Kết quả là mô hình thay đổi vĩnh viễn — nó sẽ "nhớ" những kiến thức đã học, nhưng cũng mất đi khả năng trả lời tổng quát nếu dữ liệu fine-tuning quá hẹp.

Ngược lại, **RAG (Retrieval-Augmented Generation)** không can thiệp vào trọng số mô hình. Thay vào đó, một bộ truy xuất (retriever) tìm kiếm các tài liệu liên quan từ kho dữ liệu bên ngoài, và LLM tổng hợp câu trả lời dựa trên những tài liệu đó. Kiến thức mới nằm ở nguồn dữ liệu, không nằm trong mô hình, giúp cập nhật linh hoạt mà không cần huấn luyện lại.

Sự khác biệt căn bản này dẫn đến hai khái niệm then chốt: **Behavioral Tuning** (điều chỉnh hành vi) và **Knowledge Injection** (tiêm kiến thức). Fine-tuning chủ yếu là Behavioral Tuning: nó thay đổi cách mô hình phản ứng, phong cách ngôn ngữ, hoặc ưu tiên một loại đầu ra nào đó. RAG là Knowledge Injection: nó cung cấp cho mô hình những sự kiện, số liệu, tài liệu cụ thể mà mô hình chưa từng thấy trong quá trình huấn luyện.

Bảng so sánh chi tiết

Bảng: So sánh RAG và Fine-tuning theo các tiêu chí kỹ thuật

Tiêu chí	Fine-tuning	RAG
Chi phí ban đầu	Cao: cần dữ liệu gán nhãn, tài nguyên GPU, thời gian huấn luyện	Thấp: chỉ cần xử lý dữ liệu, tạo embedding, triển khai vector database

Tiêu chí	Fine-tuning	RAG
Chi phí vận hành	Cố định sau khi huấn luyện; suy luận nhanh, không cần retrieval	Biến đổi: tăng theo số lượng truy vấn (token embedding, tìm kiếm, context token)
Độ linh hoạt	Thấp: muốn cập nhật kiến thức phải fine-tune lại toàn bộ hoặc huấn luyện thêm	Cao: chỉ cần cập nhật kho dữ liệu, không cần can thiệp mô hình
Độ chính xác	Phụ thuộc vào chất lượng dữ liệu huấn luyện; có thể bị overfit	Phụ thuộc vào chất lượng retrieval; có kiểm soát nguồn gốc
Tính cập nhật	Kém: kiến thức đóng băng sau khi huấn luyện	Tốt: dữ liệu có thể cập nhật theo thời gian thực
Khả năng giải thích	Khó: mô hình là "hộp đen"	Dễ hơn: câu trả lời có thể gắn với tài liệu nguồn
Độ trễ (latency)	Thấp: chỉ một lần gọi mô hình	Cao hơn: thêm bước retrieval, có thể thêm rerank
Rủi ro ảo giác	Vẫn có nếu dữ liệu fine-tuning không bao phủ đủ	Giảm đáng kể nếu retrieval chính xác và prompt hướng dẫn đúng

Bảng trên cho thấy rõ trade-off: Fine-tuning tối ưu cho tốc độ và ổn định khi kiến thức ít thay đổi, trong khi RAG vượt trội về khả năng cập nhật và minh bạch.

Khi nào nên dùng Fine-tuning?

Fine-tuning phát huy sức mạnh trong những tình huống bạn muốn thay đổi **hành vi cốt lõi** của mô hình. Cụ thể:

- **Điều chỉnh phong cách/tone:** Bạn muốn chatbot trả lời ngắn gọn, chuyên nghiệp, hoặc sử dụng biệt ngữ riêng của công ty.
- **Học một định dạng đầu ra cụ thể:** Ví dụ, yêu cầu mô hình luôn xuất ra JSON có cấu trúc nhất định.
- **Miền kiến thức ổn định:** Nếu bạn làm việc trong lĩnh vực y khoa, luật pháp, hay tài chính — nơi kiến thức nền tảng thay đổi chậm — fine-tune một lần có thể dùng trong nhiều tháng.
- **Yêu cầu latency cực thấp:** Khi mỗi mili giây đều quan trọng (ví dụ: chatbot giao dịch), một mô hình fine-tuned không cần retrieval sẽ nhanh hơn đáng kể.

Tuy nhiên, fine-tuning không phải là phép màu. Nếu bạn chỉ cần thêm một vài sự kiện mới, fine-tuning có thể gây ra **catastrophic forgetting** (quên kiến thức cũ) hoặc làm mô

hình trở nên quá chuyên biệt, mất khả năng tổng quát. Hơn nữa, việc gán nhãn dữ liệu và huấn luyện lại tốn kém — ước tính chi phí fine-tuning GPT-3.5 trên 100.000 mẫu có thể lên tới vài chục nghìn đô la cho một lần.

Khi nào nên dùng RAG?

RAG là lựa chọn ưu việt khi vấn đề nằm ở **kiến thức**, không phải hành vi. Cụ thể:

- **Thông tin thay đổi thường xuyên:** Bảng giá, chính sách, quy trình nội bộ, tin tức… RAG cho phép bạn cập nhật dữ liệu ngay lập tức mà không cần retrain.
- **Cần truy xuất đến nguồn gốc:** Trong môi trường doanh nghiệp, việc trích dẫn tài liệu là bắt buộc. RAG cho phép bạn gắn câu trả lời với đoạn văn cụ thể, tăng độ tin cậy.
- **Kho tài liệu lớn và đa dạng:** Khi bạn có hàng nghìn trang tài liệu kỹ thuật, hợp đồng, hoặc mã nguồn, RAG giúp mô hình truy xuất thông tin phù hợp mà không cần nhồi nhét toàn bộ vào context window.
- **Dữ liệu riêng tư, nhạy cảm:** Bạn không muốn gửi dữ liệu nội bộ lên cloud để fine-tune? Với RAG, bạn có thể chạy retriever và vector database hoàn toàn on-premise, chỉ gửi context đã chọn đến LLM.
- **Phát triển nhanh, prototype:** RAG dễ triển khai hơn nhiều so với fine-tuning. Bạn có thể có một hệ thống hoạt động trong vài ngày, trong khi fine-tuning có thể mất vài tuần để chuẩn bị dữ liệu và huấn luyện.

Trade-off tổng thể và hướng kết hợp

Không có giải pháp nào là "tốt nhất" tuyệt đối. Trên thực tế, nhiều hệ thống production kết hợp cả hai: dùng fine-tuning để định hình hành vi cơ bản (ví dụ: giọng văn doanh nghiệp), và RAG để cung cấp kiến thức cập nhật. Ví dụ: một chatbot hỗ trợ kỹ thuật có thể được fine-tune để hiểu ngữ cảnh và ngôn ngữ chuyên ngành, nhưng các bước khắc phục sự cố cụ thể được lấy từ RAG từ cơ sở tri thức công ty.

Điểm mấu chốt là hiểu rõ bản chất vấn đề: nếu bạn muốn thay đổi *cách* mô hình nghĩ và nói — hãy chọn fine-tuning. Nếu bạn muốn thay đổi *những gì* mô hình biết — hãy chọn RAG. Fine-tuning như đào tạo một nhân viên mới: tốn thời gian nhưng sau đó họ làm việc độc lập. RAG như cung cấp cho nhân viên đó một thư viện tài liệu tra cứu: nhanh chóng, linh hoạt, nhưng mỗi lần trả lời đều cần tra sách.

Chương này đã chỉ ra rằng LLM thuần túy có những giới hạn không thể vượt qua, và RAG là kiến trúc hệ thống cần thiết để bắc cầu qua những giới hạn đó. Trong chương tiếp theo, chúng ta sẽ đi sâu vào cách RAG hoạt động — từ khi nhận câu hỏi đến khi sinh câu trả lời — và xem xét từng thành phần trong pipeline.

Chương 2: RAG hoạt động như thế nào (high-level pipeline)

2.1 Luồng đi của dữ liệu: Từ API Request đến Response

Luồng đi của dữ liệu: Từ Query đến Response

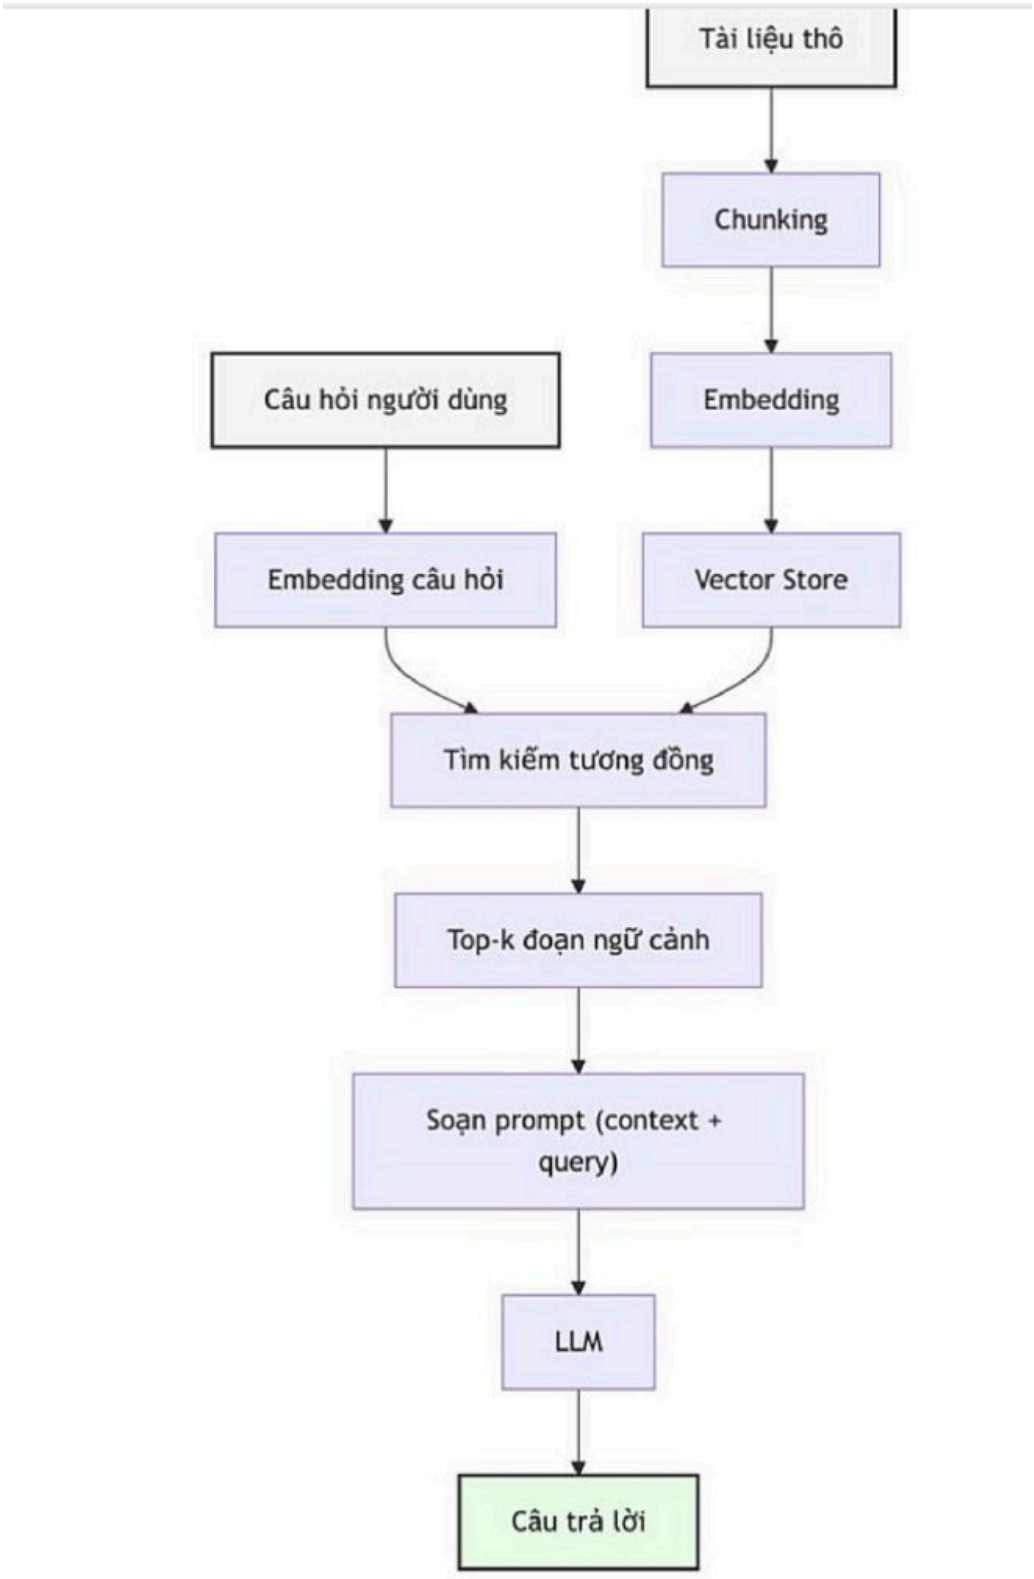
Với quyết định chọn RAG làm kiến trúc cốt lõi, câu hỏi tiếp theo là: **một câu hỏi của người dùng thực sự di chuyển qua những bước nào để trở thành câu trả lời có trích dẫn?** Đây không phải là một lời gọi API đơn giản — RAG là một pipeline gồm nhiều giai đoạn, mỗi giai đoạn có đầu vào, đầu ra và mục tiêu riêng. Hiểu rõ luồng dữ liệu này là bước đầu tiên để thiết kế và debug hệ thống sau này.

Ba giai đoạn của pipeline RAG

Một hệ thống RAG tiêu chuẩn được chia làm ba giai đoạn chính, diễn ra theo thứ tự thời gian:

1. **Indexing (Chuẩn bị dữ liệu):** Giai đoạn offline, biến tài liệu thô thành các vector có thể tìm kiếm.
2. **Retrieval (Truy xuất):** Giai đoạn online, khi có câu hỏi, tìm kiếm các đoạn văn liên quan trong kho vector.
3. **Generation (Tạo văn bản):** Giai đoạn online, đóng gói ngữ cảnh tìm được vào prompt và gọi LLM để sinh câu trả lời.

Để dễ hình dung, hãy xem sơ đồ luồng dữ liệu tổng quát:


Tài liệu thô
Chunking
Embedding
Vector Store
Câu hỏi người dùng
Embedding câu hỏi
Tìm kiếm tương đồng
Top-k đoạn ngữ cảnh
Soạn prompt (context + query)
LLM
Câu trả lời

Sơ đồ: Luồng dữ liệu RAG tổng quát

Biểu đồ trên thể hiện ba giai đoạn rõ ràng: Indexing (A→D), Retrieval (E→H), Generation (I→K). Mỗi mũi tên là một bước xử lý có thể đo lường và tối ưu riêng.

Giai đoạn 1: Indexing — Chuẩn bị kho dữ liệu có thể tìm kiếm

Indexing diễn ra **một lần** (hoặc định kỳ khi dữ liệu mới được thêm vào). Đầu vào là các tài liệu thô (PDF, HTML, văn bản thuần, code...). Đầu ra là một **vector store** — một cơ sở dữ liệu đặc biệt lưu trữ các vector và metadata.

Quy trình Indexing gồm các bước:

- **Chunking:** Cắt tài liệu thành các đoạn nhỏ (chunks) có kích thước hợp lý (thường 256–1000 token). Mỗi chunk là một đơn vị nội dung độc lập.
- **Embedding:** Dùng một model embedding (ví dụ: text-embedding-ada-002 hoặc `BGE`) để biến mỗi chunk thành một vector số thực, thường có kích thước 768 hoặc 1024 chiều.
- **Lưu trữ:** Vector cùng với metadata (nguồn tài liệu, vị trí, tiêu đề…) được đưa vào vector store như FAISS, Pinecone, hay Qdrant.

Đầu ra của giai đoạn này là một kho dữ liệu đã được **đánh chỉ mục** — sẵn sàng cho tìm kiếm ngữ nghĩa với độ trễ thấp.

Giai đoạn 2: Retrieval — Tìm kiếm ngữ cảnh liên quan

Khi người dùng gửi một câu hỏi (`query`), pipeline chuyển sang giai đoạn Retrieval. Mục tiêu: tìm ra những đoạn văn trong kho dữ liệu có nội dung liên quan nhất đến câu hỏi.

Các bước cụ thể:

1. **Embedding câu hỏi:** Sử dụng cùng model embedding với giai đoạn Indexing để vector hóa câu hỏi.
2. **Tìm kiếm tương đồng (similarity search):** So sánh vector câu hỏi với tất cả vector trong kho (hoặc với chỉ mục đã tối ưu), thường dùng độ đo cosine hoặc dot product.
3. **Chọn top-k:** Lấy ra `k` đoạn văn có điểm tương đồng cao nhất (ví dụ k=3 hoặc k=5). Các đoạn này trở thành **ngữ cảnh (context)** cho bước tiếp theo.

Đầu vào: câu hỏi văn bản.

Đầu ra: danh sách `k` đoạn văn kèm metadata (score, nguồn).

> ***Tại sao tách Retrieval ra khỏi Generation?*** *Vì mỗi khâu đòi hỏi kỹ thuật và tối ưu khác nhau. Retrieval phải nhanh (thường < 200ms) và chính*

> *xác ở mức tìm đoạn, trong khi Generation ưu tiên chất lượng văn phong và tổng hợp. Tách riêng cho phép thay thế công cụ tìm kiếm hoặc model LLM độc lập, đồng thời dễ dàng thêm các bước xử lý như reranking hoặc hybrid search mà không ảnh hưởng đến phần còn lại.*

Giai đoạn 3: Generation — Tổng hợp câu trả lời từ ngữ cảnh

Giai đoạn cuối cùng nhận hai đầu vào: (1) câu hỏi gốc của người dùng và (2) các đoạn ngữ cảnh từ Retrieval. Nhiệm vụ là tạo ra một câu trả lời tự nhiên, chính xác dựa trên ngữ cảnh đó.

Cách thực hiện: soạn một **prompt** có cấu trúc bao gồm:

- **System instruction:** Hướng dẫn cách hành xử (ví dụ: "Chỉ trả lời dựa trên ngữ cảnh dưới đây. Nếu không có thông tin, hãy nói không biết.")
- **Context:** Các đoạn văn tìm được, thường được nối với nhau và đánh dấu nguồn.
- **User query:** Câu hỏi gốc.

Prompt này được gửi đến một LLM (GPT-4, Claude, hay mô hình open-source). LLM sinh ra câu trả lời, kèm optional trích dẫn nếu prompt yêu cầu.

Đầu vào: prompt có cấu trúc (context + query).

Đầu ra: câu trả lời văn bản.

Ví dụ minh họa: Kỹ sư tra cứu tài liệu nội bộ

Giả sử một công ty có kho tài liệu kỹ thuật gồm 500 trang hướng dẫn sử dụng sản phẩm (PDF). Một kỹ sư hỗ trợ khách hàng gõ câu hỏi:

> *"Cách reset mật khẩu cho thiết bị X200?"*

Pipeline RAG xử lý như sau:

Indexing (đã hoàn thành trước đó):

- Mỗi trang PDF được cắt thành các đoạn 500 token. Ví dụ, đoạn #87: "Để reset mật khẩu thiết bị X200, nhấn giữ nút RESET trong 5 giây cho đến khi đèn vàng nhấp nháy…"
- Đoạn này được embedding thành vector và lưu vào FAISS với metadata source: "manualX200.pdf", page: 12.

Retrieval:

1. Câu hỏi được embedding thành vector `q_vec`.
2. `q_vec` được so sánh với toàn bộ vector trong kho. Kết quả top-3:
   - Đoạn #87 — score 0.92

Bảng so sánh tổng quan

Bảng: So sánh chi phí, latency, bảo mật và độ chính xác cho 1M tài liệu (200 token/tài liệu)

Tiêu chí	API (OpenAI text-embedding-3-small)	Open-source (BGE-M3, tự host GPU T4)	Ghi chú
Chi phí vận hành	~$26 (theo token)	~$10 (GPU time) + chi phí lưu trữ model	API trả per token, rẻ ở scale nhỏ; host cố định chi phí cao hơn ở scale nhỏ nhưng giảm dần khi tăng throughput
Latency (1 request)	100-300ms (tùy vị trí địa lý và load)	2-10ms trên GPU (batching có thể thấp hơn)	Open-source thấp hơn nếu cùng data center; API phụ thuộc mạng
Bảo mật dữ liệu	Dữ liệu gửi qua mạng, phụ thuộc chính sách nhà cung cấp	Dữ liệu hoàn toàn trong kiểm soát	API không phù hợp với dữ liệu nhạy cảm
Độ chính xác (MTEB benchmark)	62.3 (text-embedding-3-small)	64.4 (BGE-M3)	Chỉ số tham khảo; cần test trên dữ liệu riêng
Khả năng tùy chỉnh	Không (chỉ dùng model có sẵn)	Có thể fine-tune với dữ liệu riêng	
Triển khai ban đầu	5 phút (lấy API key)	1-3 ngày (cài đặt server, tối ưu inference)	

Bảng trên cho thấy rõ sự đánh đổi: API dễ triển khai, latency vừa phải, chi phí biến đổi; open-source khởi đầu chậm hơn nhưng linh hoạt và bảo mật hơn. Không có đáp án đúng — chỉ có đáp án phù hợp với ngữ cảnh.

Khi nào nên dùng API?

- Dự án giai đoạn đầu, cần POC/ prototype nhanh, không muốn đầu tư hạ tầng.
- Dữ liệu không nhạy cảm, có thể gửi qua mạng an toàn.
- Lượng request thấp, không đủ để justify chi phí server cố định.
- Không có đội ngũ DevOps để vận hành inference server.

Khi nào nên tự host open-source?

- Dữ liệu nhạy cảm (tài chính, y tế, nội bộ doanh nghiệp).
- Yêu cầu latency rất thấp (<50ms) hoặc throughput cao (hàng nghìn request/giây).
- Lượng embedding lớn, ổn định, cần chi phí dài hạn thấp hơn.
- Muốn fine-tune model cho domain cụ thể.

Ví dụ tính toán chi phí thực tế

Giả sử cần embedding 1 triệu tài liệu, mỗi tài liệu 200 token. Với OpenAI text-embedding-3-small: 0.13/1M token × 200M token = 26. Với BGE-M3 tự host trên GPU T4 (giả sử throughput 200 token/s): thời gian inference ~1 triệu × 200 token / 200 token/s = 1 triệu giây ≈ 278 giờ. Chi phí GPU T4 (spot) 0.11/giờ → 30.6. Cộng với chi phí lưu trữ model và CPU quản lý, tổng khoảng $35. Con số gần tương đương. Nhưng nếu xử lý 10 triệu tài liệu, OpenAI sẽ tốn $260, còn tự host vẫn ~35/ngày? Thực tế throughput không scale tuyến tính vì batching giúp tăng tốc: với batch size 32, throughput có thể lên 5000 token/s, giảm thời gian xuống còn 111 giờ, chi phí ~12. Càng nhiều dữ liệu, open-source càng rẻ.

Checklist lựa chọn model

Trước khi quyết định, hãy kiểm tra các câu hỏi sau. Nếu hầu hết trả lời "Có" cho API → chọn API; nếu cho open-source → chọn open-source.

1. Dữ liệu có nhạy cảm, không được phép gửi ra ngoài? (Nếu Có → open-source)
2. Bạn cần prototype trong vòng 1 ngày? (Có → API)
3. Latency yêu cầu <50ms? (Có → open-source với GPU mạnh)
4. Bạn có sẵn GPU và DevOps để quản lý? (Không → API)
5. Bạn cần fine-tune model cho domain riêng? (Có → open-source)
6. Lượng embedding hàng tháng ổn định và lớn (>10M tài liệu)? (Có → open-source)
7. Bạn muốn tránh vendor lock-in? (Có → open-source)

Không có checklist nào thay thế được thử nghiệm thực tế. Hãy chạy benchmark trên dữ liệu của bạn với 2-3 model đại diện cho mỗi nhóm, đo retrieval accuracy và latency, rồi mới quyết định. Việc chọn sai model có thể gây lãng phí chi phí hoặc hiệu năng kém — nhưng may mắn là bạn luôn có thể đổi model sau mà không cần thay đổi cấu trúc pipeline, nhờ vào lớp abstraction embedding API.

Ví dụ về cấu hình chọn model phổ biến:

- Startup nhỏ, POC nhanh: OpenAI text-embedding-3-small.
- Doanh nghiệp tài chính, y tế: BGE-M3 tự host trên GPU (hoặc CPU với lượng ít).
- Ứng dụng real-time, scale vừa: Cohere embed-english-v3.0 (API latency thấp, bảo mật tốt hơn OpenAI? Cần cân nhắc).

- Hệ thống nội bộ, không yêu cầu latency khắt khe: E5-mistral-7b-instruct (chất lượng cao, cần GPU).

Quyết định embedding model là bước đầu tiên trong pipeline dữ liệu. Khi đã chọn xong, bạn sẽ đối mặt với câu hỏi tiếp theo: làm thế nào để chia dữ liệu thành các đoạn nhỏ mà vẫn giữ nguyên ngữ cảnh? Đó chính là nội dung của chương tiếp theo về chunking.